


1 Architecture technique

1.1 Vue d'ensemble

L'architecture suit **quatre principes directeurs**, chacun assumé et justifié plus bas :

1. **Services découplés par domaine** : un ensemble restreint de services indépendants alignés sur les domaines métier (auth, cœur, ingestion temps-réel, téléconsultation, moteur IA), derrière une passerelle unique. Les frontières suivent les runtimes (Rust / Python) et les profils de charge, pour faire évoluer et monter en charge chaque service séparément, sans multiplier les microservices fins.
2. **Architecture événementielle** : les services communiquent via un bus (Kafka) pour se découpler et ne perdre aucun événement (ingestion, projections, alertes, audit, file de téléconsultation).
3. **IA en cage** : le Care Engine est un pipeline borné qui explique et oriente, sans jamais diagnostiquer ni écrire directement dans les données métier.
4. **Souveraineté et coût maîtrisé** : Rust économe, une seule famille de bases (PostgreSQL), hébergement UE auto-géré.

Flux : — synchrone (aller-retour) · — événement (sens unique) · — contrôle · — externe.



Plateforme & Ops (transverse) : Kubernetes auto-géré (Hetzner, Terraform) · GitOps (Argo CD) · observabilité OpenTelemetry → Prometheus / Loki / Tempo / Grafana · secrets chiffrés (SOPS). Cette couche transverse a son propre schéma de déploiement (cluster, CI/CD, observabilité, hébergement) en partie Cloud & infrastructure. Diagramme exporté du cockpit interactif : version complète et navigable sur pawrise-care.com.

Lecture par zone

- **Clients & accès** : une **app mobile native** (bien-être, localisation, alertes, chat IA, appairage BLE), un **Vet Portal web** (historique structuré + PDF normalisé) et une console **Admin**. Tout le trafic applicatif passe par **KrakenD**, une passerelle unique : un seul point d'entrée à sécuriser, qui centralise authentification, limitation de débit et routage.
- **Entrée IoT** : le **collier** parle en **MQTT sur TLS** (certificat par appareil) à un broker **EMQX**, séparé de la passerelle HTTP. MQTT est le standard IoT : pub/sub léger, QoS et mode hors-ligne gratuits, adaptés à une batterie et un réseau cellulaire instable.
- **Services métier (Rust)** : **OIDC** (identité et droits owner / vétérinaire), **Core API** (comptes, animaux, alertes), **Ingestion** (normalisation de la télémétrie), **véto & abonnement**. Chacun est un **service indépendant**, déployé et mis à l'échelle séparément selon sa charge ; ils communiquent via la passerelle et le bus d'événements plutôt que par appels directs, ce qui les garde faiblement couplés.
- **Bus d'événements (Kafka)** : la colonne vertébrale. Les services **publient** des événements ; les consommateurs (projections, Care Engine, audit, file de téléconsultation) s'y **abonnent**. Résultat : services découplés et **aucun événement perdu**.
- **IA · Care Engine (Python)** : un pipeline **LangGraph borné** qui consomme le **RAG** (pgvector) et le LLM (**Azure OpenAI UE** + reranker Cohere). Il **ne peut pas écrire** dans les données métier : il produit une orientation et, si besoin, **escalade** vers le vétérinaire via une interface contrôlée.
- **Données** : une seule famille **PostgreSQL** : transactionnel (PostgreSQL), séries temporelles de télémétrie (**TimescaleDB**) et embeddings du corpus (**pgvector**), plus **Redis** pour le cache et les sessions. Un seul moteur à opérer, sauvegarder et sécuriser.

Frontières des services

Le découpage ne suit pas l'organigramme mais **quatre critères** : **domaine métier** (bounded context), **runtime**, **profil de charge** et **frontière de sécurité**. Chaque service existe parce qu'au moins un de ces critères le sépare nettement des autres :

- **Auth · OIDC** : frontière de **sécurité** isolée (émission de jetons, RBAC, consentement RGPD) : un périmètre sensible que l'on durcit et audite séparément.
- **Core API** : le **cœur transactionnel** (comptes, animaux, abonnements) et les **règles de santé**, regroupés car ils partagent la même source de vérité et le même cycle de vie.
- **Ingestion** : **profil de charge** radicalement différent (flux MQTT haute fréquence, temps réel) : isolée pour monter en charge sans jamais impacter le transactionnel.
- **Téléconsultation / Pool** : service **avec état** (WebSocket, sessions de chat, file d'attente) : un profil de scalabilité distinct du reste.
- **Care Engine** : **runtime** imposé (Python / LangGraph, écosystème IA) : il ne peut pas vivre dans les services Rust, et son cloisonnement porte la règle « IA en cage ».

À l'inverse, on **ne fragmente pas au-delà** : tant que des données partagent le même cycle transactionnel, elles restent dans Core API. Un nouveau service ne naît que lorsqu'un des quatre critères le justifie, jamais par principe.

L'IA EN CAGE · RÈGLE D'OR

Le Care Engine n'a **aucun accès en écriture** au métier et suit un pipeline déterministe : il explique, oriente et escalade, **jamais il ne diagnostique** (Code rural, art. L243-1). Cette contrainte est portée par l'architecture elle-même, pas seulement par le modèle, ce qui la rend juridiquement défendable (ADR-001).

1.2 Choix techniques justifiés

Chaque décision structurante : besoin, alternatives écartées, décision, et trade-off assumé.

Choix	Alternatives écartées	Décision & trade-off
Rust (services métier)	Node, Python, Go, C#	Perf + sûreté mémoire, empreinte minimale. Coût dev ~2,5× assumé (mitigé : périmètre Rust ciblé sur les services critiques, Python pour l'IA, workspace Cargo partagé).
Découpage en services	Monolithe unique, microservices fins	Frontières par domaine + runtime (Rust / Python) et profil de charge (ingestion, WebSocket). Montée en charge ciblée ; surcoût d'exploitation absorbé par Kubernetes, GitOps et l'observabilité.
MQTT / EMQX (entrée IoT)	HTTP, CoAP, passerelle maison	Standard IoT : pub/sub léger, QoS, offline gratuits. Un composant de plus à opérer.
Apache Kafka (bus)	RabbitMQ, appels directs	Débit, rétention, découplage. Plus gourmand en RAM (dimensionne le cluster).
PostgreSQL + TimescaleDB + Mongo + Influx + Qdrant séparés + pgvector		Une seule famille : transactionnel, séries temporelles, vectoriel. Bascule Qdrant possible.
Pipeline LangGraph borné	Agent LLM autonome	Chaque étape testable, responsabilité juridique portée par le pipeline (ADR-001).
Azure OpenAI EU + cascade + Cohere	LLM hors UE, modèle unique	Data residency UE, ~0,03-0,05 €/conv. Dépendance Microsoft mitigée (interface LLMPProvider).
Kubernetes auto-géré + GitOps	PaaS, managé d'emblée	Économique et souverain ; plus d'ops, mitigé par l'IaC. Managé EU au scale.
OIDC maison	Auth0, Keycloak, Cognito	Souveraineté + défi formateur ; coûteux (~4-6 mois-homme), revue de sécurité obligatoire.

1.3 Scénarios & flux d'événements

Les services ne s'appellent presque jamais en direct : ils **publient** et **consomment** des événements sur Kafka, organisés en topics par domaine. Un même événement est lu par plusieurs consommateurs indépendants, qui évoluent sans se connaître : on ajoute une réaction (notification, projection, audit) sans toucher au producteur.

Topic Kafka	Producteur	Consommateurs	Charge utile
telemetry.normalized	Ingestion	TimescaleDB (série · historique)	Mesure normalisée (position, activité, température, rythme) + horodatage serveur + n° de séquence.
health.alert	Core API (règles de santé)	Notifications · Email/SMS · Care Engine	Animal, type de signal, sévérité, fenêtre d'observation.
care.escalation	Care Engine	Téléconsult/Pool (file) · Notifications	Animal, motif, résumé contextualisé, priorité.

Exemple de bout en bout : un signal faible détecté.

1. **Mesure** : le collier échantillonne en continu (activité, température, rythme) et publie en MQTT/TLS. En cas de coupure, il bufferise localement et rejoue à la reconnexion : aucune mesure perdue.

2. **Ingestion** : abonnée au broker, elle décode, **déduplique** (n° de séquence + horodatage serveur), écrit la série dans TimescaleDB et publie `telemetry.normalized` sur Kafka.
3. **Détection (Core API)** : le **module de règles de santé** de Core API compare les séries récentes de l'animal à ses **lignes de base** (activité, température, rythme, zones GPS). Baisse d'activité + légère hausse de température sur 48 h = **signal faible**.
4. **Alerte** : Core API publie `health.alert` (sévérité « faible ») ; **Notifications** et **Email/SMS** préviennent le propriétaire.
5. **Orientation IA** : saisi de l'alerte ou interrogé par le propriétaire, le **Care Engine** contextualise (RAG + historique) et propose une orientation prudente (surveiller, ou consulter). Il **ne pose aucun diagnostic**.
6. **Escalade si besoin** : si le tableau est ambigu ou s'aggrave, le Care Engine publie `care.escalation` : la demande entre dans la file de Téléconsult/Pool et le vétérinaire est notifié.
7. **Traçabilité** : l'intégralité de la conversation IA est enregistrée dans le journal d'audit (voir ci-dessous).

1.4 Résilience & disponibilité

- **Ingestion idempotente** : chaque trame porte un numéro de séquence ; l'Ingestion déduplique et réordonne par horodatage serveur. Un rejeu après coupure n'introduit ni doublon ni trou d'historique.
- **Collier hors-ligne** : buffer local et rejeu à la reconnexion, pensés pour un réseau cellulaire instable.
- **Dead-letter queue** : un événement non traitable part dans une file de rejeu (DLQ) au lieu de bloquer le flux ; il est supervisé puis rejoué après correctif.
- **Nouvelles tentatives bornées** : les appels sortants (LLM, paiement, cartographie) sont protégés par des retries avec backoff et des délais plafonnés.
- **Dégradation gracieuse de l'IA** : si le LLM est indisponible, le chat passe en file d'attente et toute situation à risque est **escaladée directement** vers le vétérinaire. La sécurité prime sur la fonctionnalité.
- **Sans état & mise à l'échelle** : les services Rust sont sans état (sessions dans Redis) et se répliquent horizontalement ; Kafka partitionne par animal pour paralléliser les traitements.
- **Sauvegardes & reprise** : PostgreSQL en restauration à un instant (PITR), snapshots des volumes, sauvegarde planifiée de l'état du cluster (détail en partie Cloud & infrastructure).
- **Objectifs de service** : ingestion et alertes traitées en continu ; disponibilité cible et latence p95 suivies via l'observabilité (NFR6, NFR7).

1.5 Sécurité & protection des données

Sécurité **par conception**, en défense en profondeur. Le détail par couche figure en parties IoT (collier), Cloud (infrastructure) et IA (Care Engine) ; voici la synthèse des frontières :

- **Frontières de confiance** : depuis Internet, tout passe par la passerelle unique (KrakenD : validation du JWT en bordure, limitation de débit) ; l'IoT entre par un broker MQTT séparé (TLS + certificat par collier, PKI step-ca) ; en interne, les services communiquent en **mTLS**.
- **Identité & moindre privilège** : OIDC avec des scopes distincts propriétaire / vétérinaire / admin. Un vétérinaire n'accède qu'aux animaux qui lui sont rattachés.
- **Chiffrement** : en transit (TLS/mTLS partout) et au repos (volumes chiffrés) ; secrets versionnés chiffrés (SOPS + age), jamais en clair dans le dépôt.
- **Données de santé & RGPD** : minimisation (on ne collecte que l'utile), rétention par finalité, résidence UE (hébergement et LLM Azure en région UE). Le droit à l'effacement s'applique aux données métier ; le journal d'audit fait exception, conservé pour la preuve juridique (voir ci-dessous).
- **IA cloisonnée** : le Care Engine n'a aucun accès en écriture au métier (ADR-001).

1.6 Traçabilité & journal d'audit

Le risque juridique majeur du produit : qu'un client affirme que l'IA a **posé un diagnostic** et nous en tiennne pour responsables (par exemple le décès de l'animal). La parade est architecturale : le Care Engine **journalise l'intégralité de chaque conversation** (entrée, passages récupérés par le RAG, sortie, décisions des garde-fous) dans un journal **append-only conservé 5 ans**. En cas de litige, on prouve mot pour mot ce qui a été dit : une orientation ou une escalade, **jamais** un diagnostic (Code rural, art. L243-1 ; ADR-010).

- **Contenu = conversations complètes** : pas de simples métadonnées ; chaque échange IA est rejouable tel qu'il s'est produit. Ces enregistrements servent aussi de base d'évaluation qualité du Care Engine.
- **Immuable (WORM)** : stockage objet append-only avec **Object Lock** (S3-compatible) : écriture seule, ni modification ni suppression pendant la durée de rétention.
- **Rétention 5 ans** : alignée sur le délai utile à la preuve en cas de mise en cause.
- **Périmètre étendu** : au-delà des conversations, les accès vétérinaire aux données d'un animal et les escalades sont également tracés.
- **Articulation RGPD** : ces échanges contiennent des données personnelles ; leur conservation malgré une demande d'effacement est justifiée par la **constitution de preuve en vue d'une action en justice** (RGPD, art. 17-3-e). Accès strictement restreint et lui-même journalisé.