

1 Cloud & infrastructure

Une infrastructure souveraine (UE / RGPD), maîtrisée en coût et prête à scaler : Hetzner auto-géré via Terraform aujourd'hui, cloud managé européen le jour où la charge le justifie. Décrite en code, déployée en GitOps.

1.1 Principes directeurs

- **Souveraineté & RGPD** — infrastructure et données de santé en UE ; Azure seulement pour le modèle de langage.
- **Infrastructure as Code** — toute l'infra en Terraform, un cluster se recrée à l'identique en une commande.
- **GitOps** — Git seule source de vérité ; Argo CD synchronise le cluster, rollback par revert.
- **Maîtrise des coûts** — lignes ARM, environnements de dev éphémères, auto-géré moins cher qu'un managé à capacités égales.
- **Observabilité** — chaque service tracé (OpenTelemetry) ; métriques, logs, traces centralisés dans Grafana.

1.2 La stack d'infrastructure

Techno	Rôle	Pourquoi
Terraform	Provisionnement	Décrit et crée toute l'infra Hetzner de façon reproductible ; détruire/recréer un environnement à la demande.
Kubernetes	Orchestration	Fait tourner et auto-répare la vingtaine de services ; redémarrage, placement, montée en charge.
Helm	Packaging	Chaque service en chart versionné et paramétrable (dev/prod).
Argo CD	Déploiement GitOps	Déploie depuis Git ; l'état du cluster suit le dépôt, rollback par revert.
SOPS + age	Secrets	Secrets chiffrés dans Git, déchiffrés uniquement dans le cluster.
step-ca	PKI interne	Autorité de certification : chaque collier et service s'authentifie en mTLS.
OTel + Prometheus/Loki/Tempo/Grafana	Observabilité	Métriques, logs et traces unifiés.
KrakenD + Traefik / cert-manager	Gateway & Ingress	Agrégation d'API, entrée HTTP et TLS automatique.

1.3 Choix d'hébergement

DÉCISION

VPS Cloud Hetzner auto-géré, lignes ARM (CAX), provisionné par Terraform. Depuis la hausse des prix Hetzner du 15 juin 2026 (jusqu'à +176 % sur les lignes AMD, +30 % seulement sur l'ARM), la ligne ARM devient la plus rentable et reste suffisante pour notre charge. Le bare metal est écarté (trop d'ops matérielle) ; le cloud managé est gardé pour le passage à l'échelle.

1.4 Stratégie en deux temps

Maintenant (dev → keynote → premiers utilisateurs) : cluster Kubernetes provisionné par Terraform (control-plane CAX21 + 2 workers CAX31, 40 €/mois), déploiement GitOps, secrets chiffrés, PKI interne, souveraineté UE.

Au scale (traction réelle) : Cloud managé EU — Scaleway Capsule (control-plane managé gratuit, PostgreSQL managé, Object Storage, GPU à la demande), sans lock-in hyperscaler. Alternative : OVHcloud Managed K8s. Azure AKS gardé pour un besoin multi-région ou SLA entreprise.

1.5 Maîtrise des coûts en développement

Un serveur arrêté reste facturé chez Hetzner : « éteindre » n'économise rien. Le bon mécanisme s'appuie sur l'laC :

- Facturation horaire avec plafond mensuel : un serveur qui n'existe que quelques heures par jour est facturé au prorata.
- Environnements de dev éphémères : terraform destroy le soir et le week-end, terraform apply le matin.
- Un cluster de dev actif 40 h/semaine (au lieu de 168) coûte 25 % du plafond, soit près de 70 % d'économie sur le compute de dev.
- Données préservées sur volumes persistants (0,05 €/Go/mois) ou snapshots ; seul le compute est recréé.

1.6 Coût annuel hors école

Scénario	Ce qu'il comprend	Coût annuel
VPS simple (auto-géré)	2× Hetzner CAX41 (ARM) + backups + volumes + Load Balancer + domaine + IA	~1 500 à 1 800 €/an
Cloud managé EU	Scaleway / OVH : 3 nœuds + PostgreSQL managé + Object Storage + LB + IA	~3 000 à 3 700 €/an
Hyperscaler (référence)	Azure AKS équivalent (multi-région, SLA entreprise)	~6 000 à 10 000 €/an

Ordres de grandeur, faible trafic et usage IA modéré. Passer hyperscaler avant d'en avoir le besoin serait du sur-engineering.