

1 IA · le Care Engine

L'assistant conversationnel contextualise l'état d'un chien à partir des données du collier, répond sur la base d'un corpus vétérinaire validé, et organise un handoff structuré vers un vétérinaire quand c'est pertinent.

RÈGLE D'OR

L'assistant n'établit jamais de diagnostic médical (Code rural, article L243-1) : il explique, oriente, et invite à consulter. Architecture : un **graphe LangGraph déterministe** à routage conditionnel (pas un agent autonome), déployé sur Azure OpenAI Europe ; la mémoire long-terme est déléguée au backend via tool calls.

1.1 LangGraph : pourquoi un graphe d'états


LangGraph décrit le raisonnement comme une **machine à états** : des **nœuds** (étapes) reliés par des **arêtes conditionnelles**. Le chemin n'est pas figé : à chaque nœud, une règle décide de la suite. On retient ce modèle contre trois alternatives :

Approche écartée	Pourquoi pas
Chaîne linéaire (LangChain simple)	Impose un chemin unique : tout passe par le RAG, même un « bonjour ». Aucun branchement propre, coût et latence inutiles.
Agent autonome (ReAct, outils libres)	L'IA décide seule de ses actions : non déterministe, difficile à tester et surtout à défendre juridiquement.
Orchestration maison (code impératif)	Réinvente le graphe, la reprise sur erreur et l'observabilité ; plus de code à maintenir, moins standard.

Le graphe donne exactement ce qu'exige un produit de santé : **branches conditionnelles** (le small-talk évite le RAG), **chaque nœud testable et journalisé**, **reprise possible**, et une responsabilité **portée par la structure** plutôt que par le bon vouloir du modèle.

1.2 Pipeline (graphe conditionnel)

Le **Circuit Breaker** classe l'intention et **route** : ce n'est pas un tuyau unique. Le RAG (recherche + reranking) n'est déclenché que pour une vraie question de santé.



Trois chemins : (1) **hors-scope / risqué** → Safe Response ou escalade, sans atteindre le LLM ; (2) **small-talk ou tour de suivi** → génération directe, sans RAG (plus rapide, moins cher) ; (3) **question santé** → RAG complet. Toutes les réponses repassent par le garde-fou post-LLM. Chaque nœud est déterministe, testable et journalisé (audit append-only, 5 ans).

Rôle de chaque nœud

Suivons une vraie question de propriétaire, « **Mon chien Rex boite depuis ce matin et mange moins** », à travers le graphe :

Nœud	Ce qu'il fait · pourquoi	Exemple (Rex)
1 · Circuit Breaker	Classe l'intention (santé / small-talk / hors-scope / risqué) et route. Bloque en amont ce qui ne doit jamais atteindre le LLM et évite le RAG inutile.	« boite + mange moins » → question santé → chemin RAG. (« merci ! » → réponse directe ; demande dangereuse → Safe Response.)
2 · Query Understanding	Reformule en termes vétérinaires et appelle le tool télémétrie du collier. Une question floue retrouve mal ; la télémétrie ancre la réponse dans les données réelles.	→ « boiterie + baisse d'appétit, chien » + lit le collier : activité -40 %, température normale sur 48 h.
3 · Retrieval (BM25 + dense)	Recherche hybride (termes exacts + sens, fusion RRF) dans le corpus vétérinaire validé. Ancre la réponse sur des sources, pas sur la mémoire du LLM (anti-hallucination).	Renvoie ~20 passages : boiterie aiguë, causes d'anorexie, signes d'alerte, quand consulter.
4 · Relevance Filter (rerank)	Reclasse les passages et garde le top-5 (Cohere Rerank). ~10× plus rapide et plus précis qu'un filtre LLM ; réduit le bruit envoyé au gros modèle.	Ne conserve que les 5 passages les plus pertinents, écarte le hors-sujet.
5 · Génération (LLM principal)	Rédige à partir de la question + top-5 + télémétrie, cite les sources, sortie JSON. Seul nœud qui exige un gros modèle (raisonnement + rédaction).	« Une boiterie avec baisse d'appétit mérite un avis : limitez l'effort, surveillez, consultez sous 24-48 h. » + citations.
6 · Post-LLM Guardrail	Vérifie la sortie : pas de formulation « diagnostic-like », ancrage sur les sources citées, règles d'escalade. Dernière barrière : force l'escalade si besoin.	Si le LLM avait écrit « Rex a une entorse » → détecté, réécrit en orientation + escalade vétérinaire.

1.3 Garde-fous (défense en profondeur, 3 couches)

- **Couche 1 · pré-LLM (Circuit Breaker)** : classifier d'intention ; tout ce qui n'est pas « clean » est dérouter vers une Safe Response ou une escalade, sans atteindre le LLM principal.
- **Couche 2 · raisonnement** : system prompt strict + whitelist de tools + obligation de citer le corpus pour tout claim médical.
- **Couche 3 · post-LLM** : détection « diagnostic-like », contrôle d'ancrage sur les sources, déclenchement forcé de l'escalade selon des règles explicites.

1.4 Périmètre

Ce qu'on fait : Q&A santé/comportement (corpus + télémétrie), contextualisation d'une alerte collier, handoff vétérinaire structuré (PDF + JSON), refus systématique du diagnostic, audit complet.

Ce qu'on ne fait jamais : diagnostic explicite, prescription/posologie, gestion d'urgences vitales (redirection urgentiste), conseils de dressage, conseils nutritionnels précis.

1.5 Observabilité & coût

Chaque nœud du graphe émet un **span OpenTelemetry** (exporté vers **Tempo**) portant `model`, `tokens.in`, `tokens.out`, `cost_eur` et sa latence. On obtient, par conversation puis agrégé dans **Grafana** : le **coût réel**, la **latence p95 par nœud**, le **taux d'escalade**, le **taux de citation** et le **taux de**

déclenchement du RAG (small-talk vs santé). Un **budget de tokens** par conversation est plafonné : un dépassement coupe proprement via le Circuit Breaker.

Coût des modèles (cascade « le modèle le moins cher qui fait le travail »)

Chaque nœud utilise le plus petit modèle qui fait le travail ; seul le nœud de génération mobilise le gros modèle.

Nœud	Modèle	Prix éditeur (entrée / sortie, 1M tokens)
1 · Circuit Breaker	nano · GPT-5.4-nano	0,20 \$ / 1,25 \$
2 · Query Understanding	nano · GPT-5.4-nano	0,20 \$ / 1,25 \$
3 · Retrieval (embeddings)	text-embedding-3-large + BM25	0,13 \$ (entrée seule)
4 · Relevance Filter	Cohere Rerank 3.5 multilingue	2,00 \$ / 1 000 recherches
5 · Génération	principal · GPT-5.4	2,50 \$ / 15 \$
6 · Post-Guardrail	nano · GPT-5.4-nano	0,20 \$ / 1,25 \$

Sources (consultées le 2 juillet 2026) : [OpenAI · API pricing](#) (GPT-5.4, GPT-5.4-nano, text-embedding-3-large) · [Cohere · pricing](#) (Rerank 3.5). Déploiement Azure OpenAI région UE (mêmes modèles). L'interface LLMPProvider (ADR-002) abstrait le fournisseur : modèles et tarifs évoluent vite, la bascule est prévue. Parité dollar/euro retenue.

COÛT PAR CONVERSATION ≈ 0,03 À 0,05 €

Répartition : génération 88 %, reranking 8 %, nœuds nano 3 %, embeddings < 1 %. Deux leviers d'économie : la **cascade** (nano pour la classification et les garde-fous, gros modèle réservé à la génération) réduit le coût d'environ 20 % vs tout envoyer au gros modèle ; le **small-talk qui saute le RAG** coûte 5× moins qu'une réponse santé. Cible de la spec (< 0,05 €/conversation) tenue. Alternative souveraine (ADR-002) : Mistral (UE), coût équivalent, données 100 % UE.

À quoi ressemblent ces tokens ?

Pour rendre le coût tangible : le pavé ci-dessous fait **≈ 2 000 tokens** (1 500 mots). Une conversation santé en traite **4×** (surtout du contexte vétérinaire récupéré par le RAG, pas la réponse), soit **8 000 tokens pour 0,03 à 0,05 €**. Autrement dit, l’essentiel de la facture, c’est le contexte qu’on donne au modèle, pas ce qu’il écrit.

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim aequale doleamus animo, cum corpore dolemus, fieri tamen permagna accessio potest, si aliquid aeternum et infinitum impendere malum nobis opinemur. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguere possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos iridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et aut officiis debitis aut rerum necessitatibus saepe eveniet, ut et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum defuturum, quas natura non depravata desiderat. Et quem ad me accedis, saluto: 'chaere,' inquam, 'Tite!' lictores, turma omnis chorusque: 'chaere, Tite!' hinc hostis mi Albucius, hinc inimicus. Sed iure Mucius. Ego autem mirari satis non quo unde hoc sit tam insolens domesticarum rerum fastidium. Non est omnino hic docendi locus; sed ita prorsus existimo, neque eum Torquatum, qui hoc primus cognomen inveniit, aut torquem illum hosti detraxisse, ut aliquam ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo delectari, quod ista Platonis, Aristoteli, Theophrasti orationis ornamenta neglexerit. Nam illud quidem physici, credere aliquid esse minimum, quod profecto numquam putavisset, si a Polyaeno, familiari suo, geometrica discere maluisset quam illum etiam ipsum dedocere. Sol Democrito magnus videtur, quippe homini erudito in geometria perfectio, huic pedalis fortasse; tantum enim esse omnino in nostris poetis aut inertissimae segnitiae est aut fastidii delicatissimi. Mihi quidem videtur, inermis ac nudus est. Tollit definitiones, nihil de dividendo ac partiendo docet, non quo ignorare vos arbitrer, sed ut ratione et via procedat oratio. Quaeprimus igitur, quid sit extremum et ultimum bonorum, quod omnium philosophorum sententia tale debet esse, ut eius magnitudinem celeritas, diuturnitatem allevatio consoletur. Ad ea cum accedit, ut neque divinum numen horreat nec praeteritis voluptates effluere patiarur earumque assidua recordatione laetetur, quid est, quod huc possit, quod melius sit, migrare de vita. His rebus instructus semper est in voluptate esse aut in armatum hostem impetum fecisse aut in poetis evolvens, ut ego et Triarius te hortatore facimus, consumeret, in quibus hoc primum est in quo admirer, cur in gravissimis rebus non delectet eos sermo patrius, cum idem fabellas Latinas aut verbum e Graecis expressas non inviti legant. Quis enim tam inimicus paene nominis Romano est, qui Ennii Medeam aut Antiopam Pacuvii spernat aut reiciat, quod se isdem Euripidis fabulis delectari dicat, Latinas litteras oderit? Synephebos ego, inquit, potius Caecilius aut Andriam Terentii quam utramque Menandri legam? A quibus tantum dissentio, ut, cum Sophocles veli potest omnium cupiditatum ardore atincto. Cupiditates enim sunt insatiabiles, quae non modo voluptatem esse, verum etiam approbantis nobis. Sic enim ab Epicuro reprehensa et correctata permulta. Nunc dicam de voluptate, nihil scilicet novi, ea tamen, quae te ipsum probaturum esse confidam. Certe, inquam, pertinax non ero tibique, si mihi probabis ea, quae dicta sunt ab iis quos probamus, eisque nostrum iudicium et nostrum scribendi ordinem adiungimus, quid habent, cur Graeca antepontant iis, quae et a formidinum terrore vindicet et ipsius fortunae modice ferre doceat iniurias et omnis monstret vias, quae ad amicos pertinerent, negarent esse per se ipsam causam non multo maiores esse et voluptates repudiandae sint et molestiae non recusandae. Itaque earum rerum hic tenetur a sapiente delectus, ut aut voluptates omittantur maiorum voluptatum adipiscendarum causa aut dolores suscipiantur maiorum dolorum effugiendorum gratia. Sed de clarorum hominum factis illustribus et gloriosis satis hoc loco dictum sit. Erit enim iam de omnium virtutum cursu ad voluptatem proprius disserendi locus. Nunc autem explicabo, voluptas ipsa quae qualisque sit, ut tollatur error omnis imperitorum intellegaturque ea, quae voluptaria, delicata, mollis habeatur disciplina, quam gravis, quam continens, quam severa sit. Non enim hanc solam voluptatem, quae suavitate aliqua naturam ipsam movet et cum iucunditate quadam percipitur sensibus, sed maximam voluptatem illam habemus, quae percipitur omni dolore careret, non modo non repugnantibus, verum etiam approbantibus nobis. Sic enim ab Epicuro sapiens semper beatus inducitur: finitas habet cupiditates, neglegit mortem, de diis immortalibus sine ullo metu vera sentit, non dubitat, si ita res se habeat. Nam si concederetur, etiamsi ad corpus ferri, nec ob eam causam non fuisse. – Torquem detraxit hosti. – Et quidem se texit, ne interiret. – At magnum periculum adiit. – In oculis quidem exercitus. – Quid ex eo est consecutus? – Laudem et caritatem, quae sunt vitae sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo et gravissimas res consilio ipsius et ratione administrari neque maiorem voluptatem ex infinito tempore aetatis percipi posse, quam ex hoc facillime percipi potest: Constituamus aliquem magnis, multis, perpetuis fruentem et animo et attento intuemur, tum fit ut aegritudo sequatur, si illa mala sint, laetitia, si bona. O praeclearam beate vivendi et apertam et simplicem et directam viam! Cum enim certe nihil homini possit melius esse quam Graecam. Quando enim nobis, vel dicam aut oratoribus bonis aut poetis, postea quidem quam fuit quem imitarentur, ullus orationis vel copiosae vel elegantis ornatus defuit? Ego vero, quoniam forensibus operis, laboribus, periculis non deseruisse mihi videor praesidium, in quo a nobis sic intelleges eitam, ut ab ipsis, qui eam disciplinam probant, non soleat accuratus explicari; verum enim invenire volumus, non tamquam adversarium aliquem convincere. Accurate autem quondam a L. Torquato, homine omni doctrina erudito, defensa est Epicuri sententia de voluptate, nihil scilicet novi, ea tamen, quae te ipsum probaturum esse confidam. Certe, inquam, pertinax non ero tibique, si mihi probabis ea, quae praeterierunt, acri animo et corpore voluptatibus nullo dolore nec impediende nec inpendente, quem tandem hoc statu praestabiliorem aut magis expetendum possimus dicere? Inesse enim necesse est effici, ut sapiens solum amputata circumcisaque inanitate omni et errore naturae finibus contentus sine aegritudine possit et sine metu degendae praesidia firmissima. – Filium morte multavit. – Si sine causa, nollem me ab eo et gravissimas res consilio ipsius et ratione administrari neque maiorem voluptatem ex infinito tempore aetatis percipi posse, quam ex hoc facillime percipi potest: Constituamus aliquem magnis, multis, perpetuis fruentem et animo et corpore voluptatibus nullo dolore nec impediende nec inpendente, quem tandem hoc statu praestabiliorem aut magis expetendum possimus dicere? Inesse enim necesse est aut in liberos atque in sanguinem suum tam crudelis fuisse, nihil ut de omni virtute sit dictum. Sed similia fere dici possunt. Ut enim virtutes, de quibus neque depravate iudicant neque corrupte, nonne ei maximam gratiam habere debemus, qui hac exaudita quasi voce naturae sic eam firme graviterque comprehenderit, ut omnes bene sanos ad iustitiam, aequitatem, fidem, neque homini infanti aut inpotenti iniuste facta conducunt, qui nec facile efficere possit, quod melius sit, accedere? Statue contra aliquem confectum tantis animi corporisque doloribus, quanti in hominem maximi cadere possunt, nulla spe proposita fore levius aliquando, nulla praeterea neque praesenti nec expectata voluptate, quid eo miserius dici aut fingi potest? Quodsi vita doloribus referta maxime fugienda est, summum bonum consequamur? Clamat Epicurus, is quem vos nimis voluptatibus esse deditum dicitis: non posse reperiri. Quapropter si ea, quae senserit ille, tibi non vera videantur. Vide, quantum, inquam, fallare, Torquate. Oratio me istius philosophi non offendit; nam et praeterita grate meminit et praesentibus ita potitur, ut animadvertat quanta sint ea quamque iucunda, neque pendet ex futuris, sed expectat illa, fruitur praesentibus ab iisque vitis, quae paulo ante collegi, abest plurimum et, cum stultorum vitam cum sua comparat, magna afficitur voluptate. Dolores autem si qui e nostris aliter existant, quos quidem video minime esse deterrum. Quae cum dixisset, Explicavi, inquit, sententiam meam, et eo quidem consilio, tuum iudicium ut cognoscerem, quoniam mihi ea facultas, ut id meo arbitratu facerem, ante hoc tempus numquam est dici. Graece ergo praetor Athenis, id quod maluisti, te, cum ad me in Cumanum salutandi causa uterque venisset, pauca primo inter nos ea, quae audiebamur, conferebamur, neque erat umquam controversia, quid ego intellegerem, sed quid probarem. Quid igitur est? Inquit; audire enim cupio, quid non probes. Principio, inquam, in physicis, quibus maxime gloriar, primum totus est alienus. Democritea dicit per pauca mutans, sed ita, ut ea, quae hoc non minus declarant, sed videntur leviora, veniamus. Quid tibi, Torquate, quid huic Triario.

Le pavé ci-dessus : ≈ 2 000 tokens. Une conversation santé complète ≈ 4 × ce pavé.

1.6 Décisions d'architecture (ADR)

ADR	Décision
001 · Pipeline borné	Graphe déterministe à routage conditionnel, pas d'agent autonome : responsabilité juridique portée par la structure.
002 · Azure OpenAI EU + cascade	Data residency UE, pas d'entraînement sur les données ; interface LLMProvider (basculable possible).
003 · Reranker dédié	Cohere Rerank 3.5 : latence ~10× meilleure qu'un filtre LLM, meilleure pertinence.
004 · Mémoire = backend	Pas de fact store dans le chatbot ; tool calls vers le Core API (source de vérité unique).
005 · Sortie JSON structurée	Le front affiche les actions sans parser du markdown fragile.
006 · RGPD progressif	MVP : masquage regex des PII ; V1 : Presidio + dictionnaire vétérinaire.
007 · Garde-fous 3 couches	Défense en profondeur : l'échec d'une couche n'expose pas le système.

ADR	Décision
008 · Retrieval hybride	BM25 (termes exacts) + dense (similarité), fusion RRF.
009 · Query Understanding	Reformulation en termes vétérinaires + tool télémétrie avant le RAG.
010 · Audit append-only	Log immuable de chaque conversation, rétention 5 ans : défense juridique et base d'eval.

1.7 Objectifs de succès (KPIs MVP)

0 faux diagnostic sur le golden set · ≥ 95 % de citation quand claim médical · 5 à 15 % de taux d’escalade approprié · réponse complète p95 < 8 s · recall@5 ≥ 0,85 · détection jailbreak ≥ 95 %.