


1 IA — le Care Engine

L'assistant conversationnel contextualise l'état d'un chien à partir des données du collier, répond sur la base d'un corpus vétérinaire validé, et organise un handoff structuré vers un vétérinaire quand c'est pertinent.

RÈGLE D'OR
L'assistant n'établit jamais de diagnostic médical (Code rural, article L243-1) : il explique, oriente, et invite à consulter. Architecture : un pipeline LangGraph déterministe borné à 6 nœuds, déployé sur Azure OpenAI Europe ; la mémoire long-terme est déléguée au backend via tool calls.

1.1 Pipeline LangGraph (6 nœuds)



Pipeline déterministe et borné : chaque étape est testable et journalisée (audit append-only, rétention 5 ans). Le LLM est cantonné à sa tâche.

1.2 Garde-fous (défense en profondeur, 3 couches)

- **Couche 1 — pré-LLM (Circuit Breaker)** : classifier d'intention ; tout ce qui n'est pas « clean » est dérouté vers une Safe Response ou une escalade, sans atteindre le LLM principal.
- **Couche 2 — raisonnement** : system prompt strict + whitelist de tools + obligation de citer le corpus pour tout claim médical.
- **Couche 3 — post-LLM** : détection « diagnostic-like », contrôle d'ancrage sur les sources, déclenchement forcé de l'escalade selon des règles explicites.

1.3 Périmètre

Ce qu'on fait : Q&A santé/comportement (corpus + télémétrie), contextualisation d'une alerte collier, handoff vétérinaire structuré (PDF + JSON), refus systématique du diagnostic, audit complet.

Ce qu'on ne fait jamais : diagnostic explicite, prescription/posologie, gestion d'urgences vitales (redirection urgentiste), conseils de dressage, conseils nutritionnels précis.

1.4 Coût des modèles (cascade « un modèle par nœud »)

Chaque nœud utilise le modèle le moins cher qui fait le travail ; seul le nœud de génération mobilise le gros modèle.

Nœud		Modèle	Prix (entrée / sortie, 1M tokens)
1 · Circuit Breaker	mini · GPT-5-nano		0,05 \$ / 0,40 \$
2 · Query Understanding	mini · GPT-5-nano		0,05 \$ / 0,40 \$
3 · Retrieval	embeddings text-embedding-3-large + BM25		0,13 \$ / 0
4 · Relevance Filter	Cohere Rerank 3.5 multilingue		2 \$ / 1 000 recherches
5 · Customization	principal · GPT-5 (ou GPT-4.1)		~1,25 à 2,50 \$ / ~10 \$

Nœud	Modèle	Prix (entrée / sortie, 1M tokens)
6 · Post-Guardrail	mini · GPT-5-nano	0,05 \$ / 0,40 \$

COÛT PAR CONVERSATION ≈ 0,03 À 0,05 €

Répartition : génération 85 %, reranking 10 %, nœuds mini 2 %, embeddings < 0,5 %. La cascade économise 30 à 35 % vs tout passer par le gros modèle. Ce coût valide la cible de la spec (moins de 0,05 €/conversation). Alternative souveraine prévue (ADR-002) : Mistral (UE), coût équivalent, données 100 % UE. Prix éditeurs en dollars, parité dollar/euro retenue.

1.5 Décisions d'architecture (ADR)

ADR	Décision
001 — Pipeline borné	6 nœuds déterministes, pas d'agent autonome : responsabilité juridique portée par le pipeline.
002 — Azure OpenAI EU + cascade	Data residency UE, pas d'entraînement sur les données ; interface LLMPProvider (basculer possible).
003 — Reranker dédié	Cohere Rerank 3.5 : latence ~10x meilleure qu'un filtre LLM, meilleure pertinence.
004 — Mémoire = backend	Pas de fact store dans le chatbot ; tool calls vers le Core API (source de vérité unique).
005 — Sortie JSON structurée	Le front affiche les actions sans parser du markdown fragile.
006 — RGPD progressif	MVP : masquage regex des PII ; V1 : Presidio + dictionnaire vétérinaire.
007 — Garde-fous 3 couches	Défense en profondeur : l'échec d'une couche n'expose pas le système.
008 — Retrieval hybride	BM25 (termes exacts) + dense (similarité), fusion RRF.
009 — Query Understanding	Reformulation en termes vétérinaires + tool télémétrie avant le RAG.
010 — Audit append-only	Log immuable de chaque conversation, rétention 5 ans : défense juridique et base d'eval.

1.6 Objectifs de succès (KPIs MVP)

0 faux diagnostic sur le golden set · ≥ 95 % de citation quand claim médical · 5 à 15 % de taux d'escalade approprié · réponse complète p95 < 8 s · recall@5 ≥ 0,85 · détection jailbreak ≥ 95 %.